Pontificia Universidad Católica de Chile
Departamento de Estadística
Tópicos Aplicados en Estadística — EYP3407
Profesor: Eloy Alvarado
Ayudante: Andrés Díaz

Proyecto final

11 de Noviembre de 2026

Estudiantes: Diego Barrios
Renato Bazaes
Mauricio Campillay
Bruno Zavala

Resumen Ejecutivo

En el presente informe, se plantea una solución al problema de determinar cuál es la probabilidad de que una solicitud municipal de plomería ingresada al Departamento de Preservación y Desarrollo de Vivienda de Nueva York tarde más de siete días en resolverse. Para ello, se propuso un modelo de clasificación binario basado en una regresión logística cuya penalización de coeficientes se adecúa a la norma Lasso. Este modelo destaca por su interpretabilidad directa y por su capacidad de eliminación de variables que no aportan realmente al análisis.

El modelo resultante considera como predictores principales el origen de la solicitud, el canal por el que esta fue enviada, el instante temporal de ingreso y el detalle técnico que se pretende solucionar. El desempeño predictivo empeoró levemente lo obtenido en las métricas de validación, pero no se observaron diferencias preocupantes que inviten a pensar que la capacidad de generalización del modelo empeore considerablemente. Se determinó que la propuesta entregada tiene un buen poder predictivo para las solicitudes que efectivamente terminaron tardando más de una semana en resolverse, pero aún presenta severas dificultades para distinguir correctamente aquellos casos en los que la resolución se consiguió en menos de siete días.

Problema de investigación

Uno de los problemas más recurrentes a los que se ve enfrentado el sistema público es la reducida capacidad de procesamiento de solicitudes dirigidas a agencias municipales. En múltiples ocasiones, se ha reportado que el tiempo que tardan estos aparatos estatales en responder a una solicitud puede extenderse más de lo esperado, lo que suele dejar un número considerable de peticiones cuya resolución tarda más de una semana, o que directamente quedan inconclusas.

En particular, en este proyecto se trabajará con datos que contienen información perteneciente a la oficina de gestión de solicitudes del Departamento de Preservación y Desarrollo de Vivienda de Nueva York (HPD), y se buscará elaborar un **modelo predictivo** capaz de anticipar **si una solicitud dirigida al área de plomería tardará o no más de siete días en cerrarse**. Para ello, se contempla el uso de una variable respuesta codificada en un indicador dicotómico $Y \in \{0, 1\}$ que tomará el valor 1 cuando la solicitud tarde más de 168 horas (7 días) en resolverse y 0 en caso contrario.

Base de datos

- **Procedencia:** Los registros pertenecientes al Departamento de Preservación y Desarrollo de Vivienda de Nueva York están disponibles en las bases de datos del repositorio `NYC Open Data`.

  La base de datos, titulada *311 Service Requests from 2020 to Present* (identificador: `erm2-nwe9`), fue descargada el día 12 de Octubre tomando como referencia el archivo `Leeme.txt` proporcionado por el profesor. Los filtros de la copia descargada incluyen:

  - ✓ Agencia municipal HPD (`agency = HPD`)
  - ✓ Solo se usan solicitudes de plomería (`complaint_type = PLUMBING`)
  - ✓ Se trabajará con solicitudes cuyas fechas de ingreso (`created_date`) estén entre 1 de enero 2021 y el 31 de diciembre de 2023

Como el objetivo de investigación es encontrar un modelo predictivo capaz de determinar la probabilidad de que una solicitud siga sin cierre administrativo, se requiere delimitar ciertos elementos fundamentales:

- **Población:** Solicitudes de plomería dirigidas a la agencia HPD entre el 01-01-2021 y el 31-12-2023.
- **Unidad de observación:** Una solicitud única (distinguibles con identificador `unique_key`)
- **Variable respuesta:** Indicador dicotómico orientado a mostrar si la solicitud municipal se resolvió en más de 7 días o no:

$$Y = \begin{cases} 0 & ; \text{ la solicitud se resolvió en a lo más 168 horas} \\ 1 & ; \text{ la solicitud se resolvió en más de 168 horas} \end{cases}$$

El siguiente paso a seguir fue la **construcción de la muestra**. Cada fila representa una solicitud diferente (con su propia `unique_key`) , por lo que no se presentaron problemas de observaciones duplicadas ni fue necesario cruzar información entre tablas.

Al realizar una **auditoría** de las observaciones almacenadas en la base, se encontraron en los datos crudos (previos a la división entrenamiento-validación) ciertos registros que ameritaban observación. Se consideró hacer una revisión con diferentes criterios; en la siguiente tabla se detallan los criterios seleccionados, la decisión tomada y el número de solicitudes que requerían revisión (n) :

Control	**Decisión**	$\boldsymbol{n}$
Fecha de inicio ausente o no interpretable	Excluir	0
Fecha de cierre anterior al 01-01-2021 (duración negativa)	Excluir	0
Sin fecha de cierre registrada	Conservar	293
Hora de cierre exacta a la medianoche	Conservar	7
Fecha de cierre más de 365 días después de fecha de inicio	Conservar	417
Registro con menos de 7 días de seguimiento	Excluir	0

Cuadro 1: Revisión de solicitudes registradas

Desde el Cuadro 1, se observa que se optó por trabajar con la totalidad de los registros disponibles en la base de datos. Las solicitudes con fecha de cierre ausentes recibieron una variable respuesta codificada como $Y = 1$ para evitar alterar la población de estudio, puesto que se podrían sesgar los resultados al no incluir solicitudes cuyo tiempo de respuesta es indeterminado.

Así, el diagrama de separación entrenamiento-validación muestra un flujo sencillo, en el que se realizó la división almacenando aproximadamente un 35 % de las observaciones para reserva y el resto para entrenamiento:

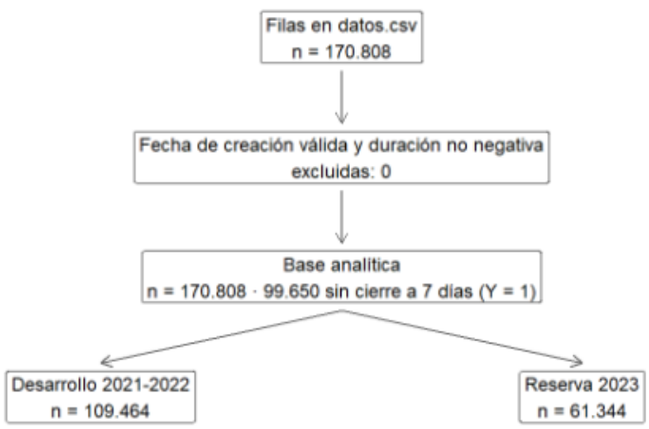


Figura 1: Flujo de construcción de la muestra

La división entrenamiento-reserva se completó respetando el orden temporal. El 35 % de los datos de reserva corresponden a las solicitudes cuyo ingreso está registrado desde el 1 de enero de 2023, mientras que las solicitudes cuyo ingreso está comprendido entre el 1 de enero del 2021 y el 24 de diciembre de 2022 pertenecen a la data de entrenamiento. Se incluye un desfase temporal de 7 días entre cada conjunto para que no se incluya en los datos de entrenamiento solicitudes cuya resolución se encuentre dentro del periodo de reserva (lo que supondría una fuga de información)

Posteriormente, se **analizaron las potenciales variables predictoras** para el modelo de interés. En el siguiente cuadro, se detallan las variables disponibles en la base de datos, si es que estas están disponibles cuando se ingresa la solicitud o en un instante posterior (columna *Disponibilidad*), la decisión tomada (si se incluye o no la variable en el modelo) y la razón por la que se tomó cada decisión:

Variable	Disponibilidad	Decisión	Razón
`unique_key`	al ingreso	excluida (identificador)	no es predictor
`closed_date`	posterior	excluida (resultado)	define Y
`status`	posterior	excluida (resultado)	revela el resultado
`resolution_description`	posterior	excluida (resultado)	describe el cierre
`resolution_action_updated_date`	posterior	excluida (resultado)	posterior al ingreso
`due_date`	incierta	excluida	SLA interno; sin registro de cuándo se fija
`created_date`	al ingreso	incluida (derivadas)	mes, día de semana y hora; año excluido porque 2023 no se observa en entrenamiento
`open_data_channel_type`	al ingreso	incluida	atributo de ingreso
`agency`	al ingreso	excluida (constante)	HPD por construcción
`complaint_type`	al ingreso	excluida (constante)	PLUMBING por construcción
`descriptor`	al ingreso (supuesto)	incluida	se supone estable tras el ingreso
`descriptor_2`	al ingreso (supuesto)	incluida	se supone estable tras el ingreso; categorías agrupadas
`location_type`	al ingreso	excluida (constante)	un solo nivel en la copia
`facility_type`	al ingreso	excluida (vacía)	información faltante
`borough`	al ingreso (supuesto)	incluida	ubicación agregada
`community_board`	al ingreso (supuesto)	incluida	ubicación agregada; categorías agrupadas
`council_district`	al ingreso (supuesto)	incluida	ubicación agregada; categorías agrupadas
`police_precinct`	al ingreso (supuesto)	incluida	ubicación agregada; categorías agrupadas
`incident_zip`	al ingreso (supuesto)	incluida	ubicación agregada; categorías agrupadas
`incident_address`	al ingreso	excluida (identificador)	no se usa ni publica
`street_name`	al ingreso	excluida (identificador)	no se usa ni publica
`bbl`	al ingreso	solo agrupación	historial de volumen, sensibilidad y bootstrap
`latitude`	al ingreso	excluida	se usa ubicación agregada
`longitude`	al ingreso	excluida	se usa ubicación agregada

Cuadro 2: Disponibilidad y decisión de inclusión de los predictores.

Nota: El detalle sobre el significado de cada una de las variables involucradas está disponible en la sección *Diccionario* del Anexo.

Para finalizar, se puede realizar una breve **Descripción de la muestra**: La base analítica dispone de 170808 solicitudes únicas, correspondientes a 33615 inmuebles (bbl) diferentes. Estas solicitudes fueron ingresadas entre el 1/1/2021 y el 31/12/2023. La prevalencia de la variable respuesta (solicitud cuyo cierre tardó más de 7 días) es de un 58.3 %.

- El detalle de la auditoría de la respuesta (distribución por año, valores faltantes y cardinalidad de las categorías) está disponible en el Anexo.

Diseño de evaluación

En primer lugar, se consideró utilizar un **Esquema de Particiones** tanto para proponer la división de datos de entrenamiento y evaluación, como para determinar los pliegues internos de validación dentro de los datos con los que se pretende entrenar el modelo. Véase la Figura 2 :

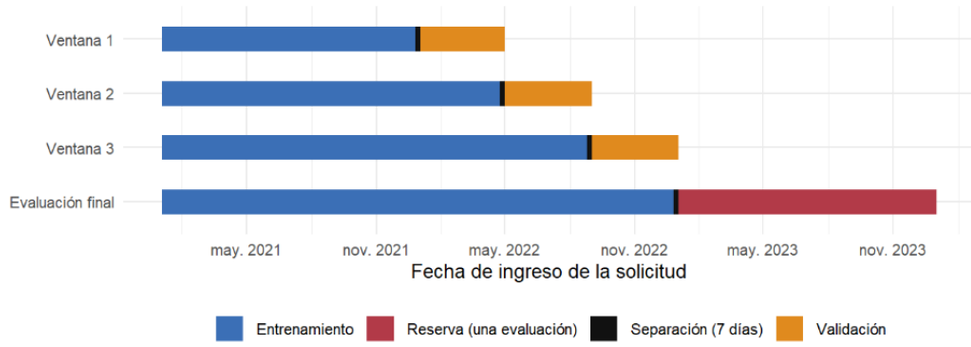


Figura 2: Esquema de particiones de entrenamiento, validación y evaluación

La lectura de la Figura 2 parte de la base de que las solicitudes del año 2021 y 2022 pertenecen a los datos de entrenamiento, mientras que las solicitudes del 2023 son almacenadas en la reserva de evaluación. Considerar que, respecto a la construcción de las particiones correspondientes, es relevante puntualizar:

- **Inclusión datos entrenamiento:** Se incluyen solicitudes cuya fecha de ingreso + 168 horas sea anterior a la fecha de inicio del periodo de validación. Con ello se garantiza que, para todos los datos de entrenamiento, sea conocido el valor de la variable respuesta Y
- **Ventanas de validación:** Se confeccionaron tres pliegues diferentes con la finalidad de realizar una validación cruzada temporal a través de ventanas expansivas. Los datos de validación son usados para calcular el error obtenido y ver cómo evoluciona el mismo a medida que avanza el tiempo. Esto último sirve para calibrar la estabilidad del modelo.
- **Datos de reserva:** Utilizando la fecha del último día dentro de la tercera ventana de validación, se le suman 7 días para que los datos de evaluación final comiencen el 1 de enero de 2023.

En la Tabla 3 se presenta un resumen con las fechas utilizadas por cada pliegue de entrenamiento, validación y evaluación; también se incluye el tamaño de cada sub-muestra involucrada:

Pliegue	Fecha datos entrenamiento	Fecha datos validación	n entrenamiento	n validación
Ventana 1	1 enero 2021 – 24 diciembre 2021	1 enero 2022 – 30 abril 2022	51 032	20 083
Ventana 2	1 enero 2021 – 23 abril 2022	1 mayo 2022 – 30 agosto 2022	71 001	17 152
Ventana 3	1 enero 2021 – 24 agosto 2021	1 septiembre 2022 – 31 diciembre 2022	88 057	20 315
Evaluación	1 enero 2021 – 24 diciembre 2022	1 enero 2023 – 31 diciembre 2023	109 464	61 344

Cuadro 3: Distribución de muestras en el diseño de evaluación

En cuanto a la **información admisible** para el modelamiento, es posible observar desde el Cuadro 2 que se ingresarán predictores que estén disponibles únicamente en la fecha de ingreso de la solicitud. Adicionalmente, el equipo confeccionó tres variables de historial que pueden ser de utilidad para el modelamiento:

- ⋆ `hist_vol_cb_7d` = Número de solicitudes en un mismo distrito durante los 7 días previos al ingreso de la última solicitud.
- ⋆ `hist_vol_cb_90d` = Número de solicitudes en un mismo distrito durante los 90 días previos al ingreso de la última solicitud.
- ⋆ Tasa de solicitudes sin cierre administrativo en los últimos 90 días para un distrito determinado. (Se excluye el horizonte inicial de 7 días para asegurar que $Y = 1$)

En caso de que algunas de las variables mencionadas sea una observación faltante (`NA`) porque el distrito (`borough`) no presentó solicitudes antes, se realizó una imputación simple utilizando la mediana. Para el caso en el que el origen de la solicitud aparezca como ubicación no especificada, se trabaja con todas esas solicitudes como si formaran parte de una misma categoría.

Selección de métricas:

Considerando que el modelo propuesto corresponde a un **clasificador binario**, se requiere utilizar métricas que **cuantifiquen su capacidad de acierto** al ajustar el comportamiento de la variable respuesta. En este marco, se tomaron los siguientes indicadores:

- **Pérdida logarítmica (métrica principal):** Es una métrica utilizada para penalizar el ajuste de las probabilidades predichas (p_i) por el modelo frente a las etiquetas reales (y_i):

$$\text{Log-Loss} \quad = \quad -\frac{1}{N}\sum_{i=1}^{N}\Big[y_i \log(p_i) + (1-y_i)\log(1-p_i)\Big] \tag{1}$$

  Las principales razones para escoger esta métrica son su capacidad para penalizar errores severos: Si el modelo predice erróneamente con total seguridad (i.e. $\exists\, i \in \{1, ..., N\} \;:\; p_i \approx 0 \;\wedge\; y_i = 1$) la penalización $\text{Log-Loss} \to \infty$. Por otro lado, la convexidad de la función de pérdida facilita la optimización para que los algoritmos puedan calcular los parámetros involucrados.

- **Métricas complementarias:** Otras formas con las que se evaluará el desempeño del clasificador se presentan a continuación:
  - ⇒ Matriz de confusión
  - ⇒ Sensibilidad (capacidad de capturar verdaderos positivos)
  - ⇒ Área bajo la curva ROC (AUC)
  - ⇒ Índice de Youden (necesario para escoger el umbral de clasificación)
  - ⇒ Precisión (mide la confiabilidad de una predicción positiva)
  - ⇒ Índice de Brier

Modelo de referencia:

Se usó como modelo de referencia la **tasa histórica de solicitudes sin cierre durante al menos 7 días**. Esta métrica es calculada únicamente en el conjunto de entrenamiento; la Tabla 4 detalla las tasas observadas en cada partición:

Pliegue	Ventana 1	Ventana 2	Ventana 3	Evaluación
Tasa	0.585	0.591	0.589	0.592

Cuadro 4: Tasas históricas de solicitudes con cierre tardío en data de entrenamiento

Regla de selección de modelos:

En un principio, se escogerá el modelo que minimice la función de pérdida logarítmica promedio entre las tres ventanas. Si un modelo más simple queda a una distancia < 0.002 unidades del modelo con menor pérdida, se escoge el modelo más parsimonioso.

Metodología

En la presente sección se mostrará el detalle sobre la propuesta de referencia y los tres modelos candidatos que se probarán en los datos de entrenamiento. En este apartado se comentará el proceso de selección de hiperparámetros en cada estrategia y el presupuesto de costo computacional en el ajuste. Posteriormente, se detallará cómo se procesan los datos antes de ingresarlos a las distintas estrategias de modelamiento con las que se abordará el problema de investigación.

Procedimientos realizados:

A parte del modelo se referencia, se propuso confeccionar un clasificador basado en tres estrategias diferentes. En el siguiente listado, se detallan cada uno de los enfoques seleccionados:

⋆ **Tasa histórica (referencia):** Este modelo predice para todas las solicitudes la misma probabilidad. Se toma el promedio simple del indicador dicotómico Y para señalar qué tan probable es que una solicitud tarde más de 7 días en resolverse:

$$\hat{p} \;=\; \frac{1}{N}\sum_{i=1}^{N} y_i \tag{2}$$

Evidentemente, este modelo es tremendamente simple y está lleno de limitaciones, como podría ser su incapacidad para distinguir entre las diferentes características de cada solicitud. Este modelo de referencia sirve para declarar un estándar mínimo, tal que se debe descartar de inmediato cualquier propuesta que no mejore el desempeño del clasificador más simple.

⋆ **Modelo 1 − Regresión logística penalizada:** Como primer acercamiento, se tomó un modelo de regresión logística que calcula el vector de coeficientes $\boldsymbol{\beta}$ asociados a los predictores estandarizados $\boldsymbol{z}$ (la estandarización solo se ejecuta para este modelo).

Se escogió la norma L_1 como criterio de penalización de complejidad, lo que implica que se trabajó con una penalización *Lasso*. Con ello, la selección de variables se consigue minimizando la función:

$$\mathcal{L}(\boldsymbol{\beta}) \;=\; -\frac{1}{N}\sum_{i=1}^{N}\Big[y_i(\beta_0+\boldsymbol{z}_i^{\top}\boldsymbol{\beta}) - \log\big(1+\exp(\beta_0+\boldsymbol{z}_i^{\top}\boldsymbol{\beta})\big)\Big] \;+\; \lambda\sum_{j=1}^{p}|\beta_j|$$

Existen varias razones para escoger esta función de penalización; entre ellas, vale la pena destacar:

- ✓ Tras ejecutar el pre-procesamiento de los datos, se tiene una matriz de predictores con un alto número de columnas. No utilizar penalización dificultaría la convergencia del modelo.
- ✓ La función de penalización Lasso transforma a 0 los coeficientes menos significativos, lo que permite reducir la complejidad de la propuesta sin ejecutar procedimientos de selección adicionales.
- ✓ La selección de variables facilita la interpretación de coeficientes y resultados.

Particularmente, el hiperparámetro a ajustar se encuentra en la penalización (λ) involucrada en la selección de variables. La elección de este hiperparámetro se ejecuta probando diversos valores de λ que darán origen a modelos diferentes. En este caso, se usó una grilla de 20 valores de λ :

$$\Lambda \;=\; \{0.00001\,,\,0.0050095\,,\,\ldots\,,\,0.0950005\,,\,0.1\}$$

Estos modelos son comparados calculando la función de pérdida logarítmica obtenida al predecir sobre la data de validación. Aquel valor de λ que minimice la función *Log-Loss*, será escogido como hiperparámetro final. Los valores de la grilla fueron escogidos tal que se pudiera comparar entre valores cuya penalización asociada fuera prácticamente nula ($\lambda =$ `1e-05`) y valores que produjeran una penalización estricta ($\lambda = 0.1$)

Por último, de este modelo se puede señalar que su principal debilidad es que captura interacciones estrictamente aditivas, por lo que para poder modelar interacciones es necesario especificarlas.

⋆ **Modelo 2 − Árbol de clasificación podado:** Como enfoque alternativo, se consideró construir una estructura de 'preguntas binarias' (*Sí/No*) para dividir las solicitudes en múltiples sub-grupos. Al momento de proponer un clasificador de este estilo, surgió la disyuntiva de si utilizar Árboles de Clasificación o Máquinas de Soporte Vectorial (SVM). La decisión tomada por el equipo fue usar Árboles de Clasificación debido a que estos cumplen con las siguientes ventajas:

- ✓ Permite obtener resultados interpretables y es posible discutir la estructura de los cortes.
- ✓ Ajustar un SVM implicaba implementar un kernel y escala determinados, lo que habría dificultado la interpretación del resultado final.

En esta oportunidad, el hiperparámetro involucrado en el modelamiento está relacionado con la complejidad del modelo. El parámetro `cost_complexity` se encarga de controlar el compromiso entre el tamaño del árbol y la calidad del ajuste. Para determinar cuál es el valor más adecuado, se utilizó una metodología similar a la vista en el modelo logístico: se propuso una grilla de 20 valores (comprendidos entre 10^{-5} y 10^{-2}) y se escogió el parámetro que minimizara la pérdida logarítmica:

$$\texttt{cost_complexity} \;=\; \{0.00001\,,\, 0.0005095\,,\, \ldots\,,\, 0.0095005\,,\, 0.1\}$$

Adicionalmente, se fijó un número de observaciones mínimo por hoja ($n_{\text{mín}}$) para evitar que se generen nodos con muy pocas observaciones, lo que conllevaría a un modelo sobreajustado que puede tener probabilidades p_i extremadamente cercanas a 0 ó 1.

La principal limitación de esta propuesta es su posible alta sensibilidad frente a cambios en la muestra de entrenamiento, tal que si se modifican levemente los datos ingresados, el árbol obtenido puede ser considerablemente diferente.

⋆ **Modelo 3 − Boosting:** Por último, se tomó como posible camino ensamblar secuencialmente múltiples modelos predictivos débiles para crear un modelo más preciso. Esta técnica, denominada como *Boosting*, destaca por su flexibilidad y su capacidad para corregir predicciones érroneas:

- ✓ Boosting permite controlar explícitamente parámetros como: el número de árboles, la profundidad de los mismos, la tasa de aprendizaje o el número de nodos. Todo esto facilita la búsqueda de hiperparámetros.
- ✓ Cada modelo sucesivo se enfoca específicamente en corregir los errores o residuos (predicciones incorrectas) que cometió el modelo anterior.

En la Tabla 5, se muestra a detalle los hiperparámetros involucrados. Tal y como se detalló en las ventajas de esta propuesta, notar como se tiene mayor precisión respecto a los parámetros de trabajo del modelo:

Hiperparámetro	Rango de valores	Justificación
`trees`	$100 - 600$	Si usan menos de 100 árboles pueden no corregirse todos los errores, con más de 600 la ganancia deja de ser significativa
`tree_depth`	$2 - 7$	Profundidades bajas son suficientes como para controlar la interacción, con más de 7 niveles se suele sobreajustar.
`learn_rate`	$10^{-7} - 10^{-2}$	Cubre el aprendizaje entre predicciones con una tasa lenta a moderada para correcciones confiables.
`min_n`	$5 - 50$	Evita la generación de hojas con muy pocas solicitudes
`mtry`	0.8	Cada árbol usa el 80 % de las columnas de la matriz de predictores; se reduce la correlación entre árboles.
`sample_size`	0.8	Cada árbol usa una sub-muestra diferente que toma 80 % de los datos; también sirve para evitar árboles muy correlacionados.

Cuadro 5: Hiperparámetros de modelo *Boosting*

La potencial desventaja de esta estrategia de modelamiento es que *Boosting* es un algoritmo de 'caja negra', por lo que es difícil diagnósticar internamente su funcionamiento. A lo anterior hay que sumarle que posee un mayor costo computacional y que es mayor el riesgo de sobreajuste si no se aplica un control estricto.

Pre-procesamiento de los datos:

Antes de comenzar con la ejecución de cada una de las propuestas presentadas, algunos de los predictores incluidos necesariamente deben ser pre-procesados. Concretamente, fue requerido el manejo de información faltante (`NA`), la adaptación de variables categóricas y la eliminación de información poco relevante. En el próximo listado están las modificaciones más importantes:

1) **Imputación valores faltantes:** Se trabajó con la mediana para los registros numéricos. Imputar con el promedio puede producir sesgos debido a su sensibilidad a valores extremos.
2) **Agrupamiento de categorías:** Variables como `incident_zip` (193 categorías) o `community_board` tienen un amplio número de niveles. Para reducirlos, se condensó en una categoría única a aquellas categorías que, marginalmente, representaran menos del 0.5 % de las solicitudes registradas.
3) **Codificación variables categóricas:** Convierte categorías en variables indicadoras (*dummy*) para que la confección de árboles de decisión o *Boosting* reciba matrices con argumentos numéricos.
4) **Eliminación columnas constantes:** Se eliminan aquellas variables que no tengan ninguna información o que todas posean un mismo valor. Esto es obvio, porque predictores de esta naturaleza no aportan nada al ajuste predictivo.
5) **Normalización variables numéricas (Solo para modelo 1)** El uso de coeficientes penalizados exige que se trabaje con variables estandarizadas, por lo que se ejecutó este procedimiento para los datos de entrada en el modelo 1.

Resultados principales

Una vez ejecutado el ajuste en entrenamiento y calculado los hiperparámetros óptimos en la fase de validación, se obtuvo para cada una de las propuestas planteadas los siguientes hiperparámetros:

Modelo	**Hiperparámetros**	**Resultado**
Modelo 1: Logístico	Penalización por complejidad (λ)	$\lambda \approx 0.00207$
Modelo 2: Árbol de clasificación podado	Costo de complejidad	`cost_complexity` ≈ 0.000546
Modelo 3: Boosting	Múltiples parámetros	100 árboles
		3 niveles de profundidad
		Tasa aprendizaje 0.091
		$n_{\text{mín}} = 21$

Cuadro 6: Resumen de hiperparámetros obtenidos para cada modelo

Posteriormente, se comienza la comparación de las métricas de ajuste planteadas en la sección de Diseño. En el Cuadro 7 se muestran los resultados en cada una de ellas:

Modelo	**n**	**Prev.**	**Log-loss**	**Dif. ref.**	**Brier**	**AUC**	**Sens.**	**VPP**
Boosting (3)	57550	0.5983	**0.6163**	-0.0580	0.2133	0.6685	0.8300	0.6897
Logística−Lasso (1)	57550	0.5983	0.6182	-0.0561	0.2143	0.6647	0.8180	0.6894
Árbol podado (2)	57550	0.5983	0.6193	-0.0550	0.2147	0.6584	0.8251	0.6892
Referencia	57550	0.5983	0.6743	0.0000	0.2406	0.5000	NA	NA

Cuadro 7: Comparación de métricas de desempeño entre modelos candidatos.

Si la revisión se realizaba únicamente por la elección de la minimización de la función de pérdida logarítmica, el modelo Boosting hubiera sido el candidato más adecuado. No obstante, al revisar sus diferencias de desempeño en validación con los modelos de regresión logística y árbol podado, se observa que las diferencias entre pérdidas logarítmicas del modelo 1 y el modelo 3 son inferiores a 0.002 unidades.

Como se discutió en la sección de ventajas y desventajas de cada modelo, el principal defecto de los modelos Boosting es su elevado costo computacional y, por tanto, el modelo más parsimonioso entre dos propuestas cuyo desempeño en validación se considera 'similar' es el modelo logístico penalizado.

En consecuencia, se escoge al Modelo 1 como la propuesta más adecuada.

- *Umbral de probabilidades:* Calculando el Índice de Youden se encuentra el punto que equilibra mejor la sensibilidad y especificidad en la data de validación. El resultado entregado fue el siguiente:

$$\text{Índice de Youden} \ = \ 0.568$$

  Esto quiere decir que si las probabilidades estimadas para una solicitud son mayores a 0.568, esta se clasifica como $Y \ = \ 1$. Por tanto, toda solicitud cuya probabilidad estimada supere el umbral será clasificada como una que se demorará más de 1 semana en resolverse.

- *Análisis de Sensibilidad:* Manteniendo fijos los hiperparámetros elegidos, se ejecutó un análisis de sensibilidad realizando la eliminación de ciertos predictores o de ciertos registros. En particular, se consideraron dos análisis diferentes:

  ✓ **Representación (Sensibilidad 1):** Se retiran las variables de historial creadas anteriormente, para evaluar si su aporte es significativo más allá de los atributos de ingreso.

  ✓ **Población (Sensibilidad 2):** Se retira una solicitud si el mismo inmueble registró otra del mismo detalle en los siete días previos, esto es de utilidad para evaluar el efecto de las solicitudes repetidas.

  A continuación, se tiene la comparación solicitada:

Escenario	Modelo	n	Log-loss	Dif. ref.	AUC
Base	M3: boosting	57550	0.6164	-0.0579	0.6682
Base	M1: logística lasso	57550	0.6182	-0.0561	0.6647
Base	M2: árbol podado	57550	0.6193	-0.0550	0.6584
S1: sin historial	M3: boosting	57550	0.6169	-0.0574	0.6667
S1: sin historial	M2: árbol podado	57550	0.6190	-0.0553	0.6590
S1: sin historial	M1: logística lasso	57550	0.6194	-0.0549	0.6606
S2: sin repetidas por inmueble	M3: boosting	44540	0.6122	-0.0549	0.6573
S2: sin repetidas por inmueble	M2: árbol podado	44540	0.6138	-0.0534	0.6422
S2: sin repetidas por inmueble	M1: logística lasso	44540	0.6140	-0.0531	0.6545

Cuadro 8: Desempeño de modelos por escenario.

  Desde el Cuadro 8 , es posible afirmar que las variables de historial influyen positivamente en la capacidad de clasificación de todos los modelos propuestos. Esto llega hasta el punto de que la elección de propuesta cambia debido a que el modelo logístico empeora lo suficiente su capacidad de ajuste como para preferir la propuesta de *Boosting*.

  Por otra parte, las observaciones repetidas actúan como un factor confusor para los modelos ajustados. Al eliminarlas, los tres modelos candidatos reducen su pérdida logarítmica, aunque no se generan diferencias significativas entre los tres; es por este motivo que, aún eliminando los datos repetidos por inmueble, por criterio de parsimonia se sigue seleccionando el modelo logístico penalizado.

Desempeño en datos de reserva:

Una vez se revisó el desempeño en los datos de entrenamiento−validación, es necesario reportar cómo funciona el modelo seleccionado sobre la información sellada para la prueba. Primero, se tiene un cuadro comparativo que muestra cómo fue la capacidad predictiva de las tres propuestas planteadas a lo largo de este proyecto.

Cabe recalcar que esta comparación tiene fines principalmente ilustrativos, puesto que, independiente de la comparativa de desempeños, se continuará utilizando el modelo escogido en la etapa de entrenamiento −validación para los análisis posteriores.

Modelo	Log-loss	Diferencia vs. referencia	Brier	AUC
Modelo 2: Árbol	0,6268	−0,0582	0,2188	0,653
Modelo 3: Boosting	0,6274	−0,0577	0,2188	0,659
Modelo 1: Logístico (elegido)	**0,6292**	**−0,0559**	**0,2198**	**0,656**
Referencia	0,6850	0	0,2459	0,500

Cuadro 9: Resultados de métricas de evaluación para los modelos.

Se reporta que el desempeño predictivo del modelo logístico empeora levemente a las otras dos propuestas, esto puede deberse a que el Modelo 1 puede tener una mayor rigidez en comparación con los árboles de clasificación. De todos modos, las diferencias encontradas son leves y no suponen una diferencia preocupante en la incapacidad de generalización.

Ahora bien, se procederá a reportar más detalles sobre el desempeño predictivo del modelo logístico en los datos de reserva:

- **Matriz de confusión:** Utilizando el umbral reportado previamente en la reserva, se tiene la siguiente comparación entre aciertos y fallos:

	Predicho: sin cierre	Predicho: con cierre
Real: sin cierre ($Y = 1$)	29 532	5 307
Real: con cierre ($Y = 0$)	15 687	10 818

Cuadro 10: Matriz de confusión del modelo logístico.

  Desde esta matriz, es posible calcular que:

  - ✓ La *sensibilidad* es de un $84.8\,\%$, lo que implica que, aproximando, de cada 100 solicitudes que realmente se demoraron, el modelo detecta 85.
  - ✓ El VPP $= 65.3\,\%$ implica que, de 100 solicitudes que el modelo marca como 'riesgosas' (que clasifica como solicitudes que se van a demorar), 65 de ellas efectivamente se demoraron.
  - ✓ La *especificidad* es de un $40.8\,\%$, por lo que de cada 100 solicitudes que cerraron a tiempo, el modelo solo reconoce 41. Ello se ve reflejado en el elevado número de falsas alarmas arrojadas por el clasificador.

- **Calibración:** Se comparó si es que al ajustar las probabilidades predichas por el modelo, estas efectivamente coinciden con la frecuencia real de los eventos observados.

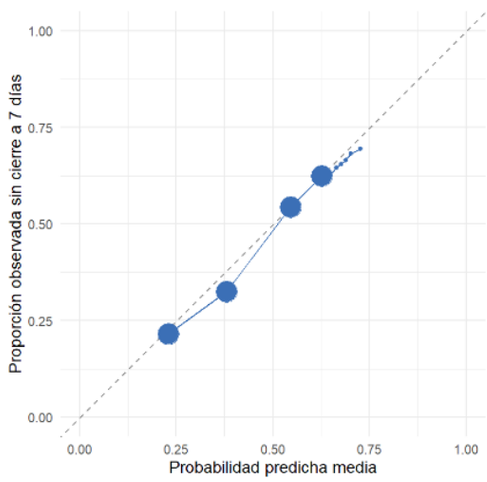


Figura 3: Calibración del modelo logístico

Existen desviaciones en la pendiente ideal de calibración en la zona central. El modelo está seguro con un 40 % de probabilidad de que la solicitud se demorará cuando el evento ocurrió el 50 % de las veces. Este fenómeno puede deberse a que el año 2023 tuvo menos solicitudes de cierre que el año de entrenamiento (Tasa 2023 = 56.8 % , Tasa entrenamiento = 59.2 %)

- **Análisis de incertidumbre:** Se chequeó si es que la mejora alcanzada por el modelo logístico en comparación a la referencia (diferencia de Log-Loss: -0.056) se debe o no al azar. Se utilizó bootstrap: se repitió 2 000 veces el cálculo sobre muestras de los datos tomadas con reemplazo, y se vio cuánto varía la diferencia de pérdida logarítmica:

Unidad remuestreada	N.º de unidades	Intervalo 95 % de la diferencia
Edificio (bbl)	18 082	$[-0,060; -0,052]$
Distrito comunitario	65	$[-0,061; -0,051]$
Semana de ingreso	53	$[-0,061; -0,050]$
Mes de ingreso	12	$[-0,065; -0,046]$

Cuadro 11: Intervalos del 95 % de la diferencia según unidad remuestreada.

Ningún intervalo incluye el 0, por lo que la mejora sobre la referencia no es casualidad, sin importar cuál sea la forma de agrupar.

- **Diagnóstico de error:** En la siguiente Figura, se muestran varios gráficos con los distintos indicadores de diagnóstico:

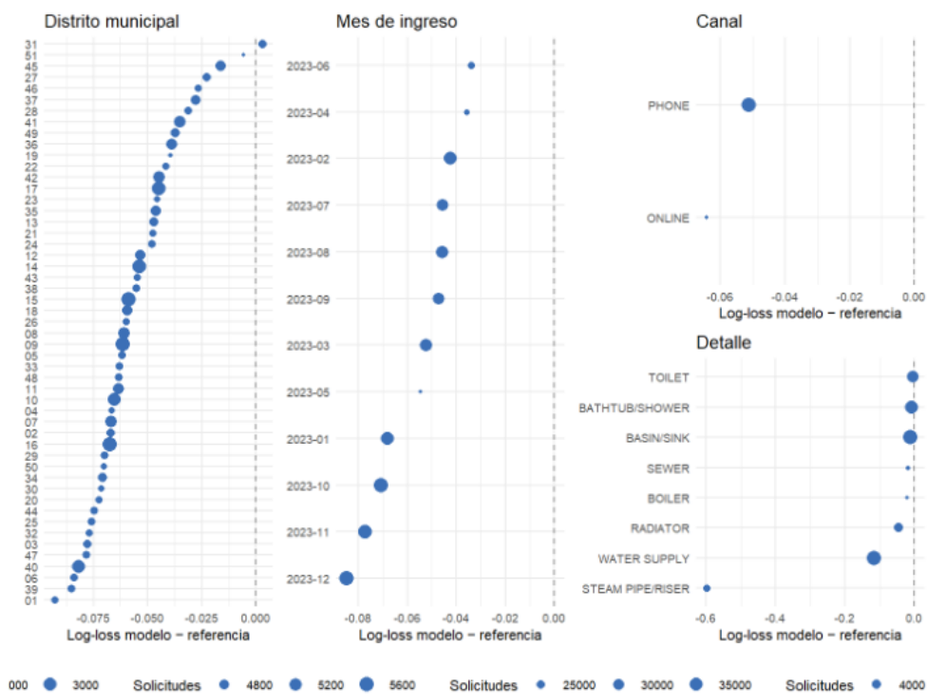


Figura 4: Diagnóstico de errores

Se revisó el error encontrado por distrito, mes, canal y detalle de la solicitud. En todos los casos se respetó el tamaño de cada grupo. El análisis se divide en lo siguiente:

- **Revisión de extremo superior:** al 1 % de solicitudes con mayor riesgo el modelo le asigna en promedio 75,6 % y la tasa real es 71,7 %
- **Revisión de extremo inferior:** Al 1 % de menor riesgo le asigna 11,0 % y la real es 4,9 %.
  En conclusión: en las colas el modelo tiende a exagerar un poco.

Discusión

En este apartado se comentarán los resultados principales ya comentados en las secciones anteriores. Además, se responderá la pregunta de investigación y se detallará tanto el uso como las limitaciones del modelo planteado.

Al ingresar una solicitud, ¿Cuál es la probabilidad de que siga sin cierre administrativo al cumplirse siete días?

En base a los resultados entregados por el modelo seleccionado, la probabilidad de que una solicitud se demore más de siete días en ser resuelta depende de las características de la misma. El modelo es especialmente potente al clasificar solicitudes cuya antigüedad es más baja, es decir: solicitudes más recientes. Las probabilidades entregadas también modifican su fiabilidad según el distrito desde el que se originaron.

El modelo es un clasificador fiable cuando interesa trabajar con solicitudes que realmente no fueron cerradas en un plazo de 7 días, pero la probabilidad entregada deja der fiable si es que la solicitud se termina cerrando efectivamente en un futuro.

Limitaciones principales:

- Las conclusiones corresponden a solicitudes de plomería de HPD creadas entre 2021 y 2023, y no se extienden a otras agencias, categorías o periodos.
- Sólo se observan las solicitudes efectivamente registradas: quienes no reclaman no aparecen.
- El cierre administrativo no equivale a resolución material del problema.
- La copia contiene el estado revisado a octubre de 2026. La evaluación es retrospectiva bajo el supuesto de que los atributos elegidos no cambiaron tras el ingreso, y no acredita rendimiento operativo real.
- Los cierres ausentes se tratan como no cierre al corte, aunque puede existir rezago.

Uso recomendado del modelo:

1) **Misma población:** Aplicable únicamente a solicitudes de plomería dirigidas al HPD de Nueva York, bajo los mismos canales y categorías. No debe extrapolarse a otras agencias, tipos de reclamos o ciudades.
2) **Priorización por riesgo:** Presenta una capacidad de discriminación moderada ($AUC \approx 0.66$). Es adecuado para ordenar solicitudes según riesgo de demora, pero no para predecir con certeza el resultado de un caso individual.
3) **Aceptación de falsas alarmas:** Identifica aproximadamente el 85 % de las solicitudes demoradas, aunque cerca de un tercio de las solicitudes marcadas se resuelven a tiempo. Resulta útil cuando el costo de revisar casos adicionales es bajo.
4) **Recalibración periódica:** Debido a cambios observados en 2023, el modelo tiende a sobreestimar el riesgo. Antes de su implementación debe recalibrarse el umbral o la probabilidad de referencia y mantenerse bajo monitoreo continuo.
5) **Calidad de los datos de entrada:** Se asume que variables como canal, detalle y ubicación son registradas correctamente al momento de ingresar la solicitud y que no son modificadas posteriormente.

Situaciones en las que no se recomienda su uso:

- En grupos con escasa evidencia o pocos datos históricos (por ejemplo, distrito 31 o categorías poco frecuentes como `BOILER` y `SEWER`).
- Para negar, postergar o restringir la atención de una solicitud.
- Para extraer conclusiones causales sobre los factores asociados a las demoras.
- Como garantía de resolución efectiva del problema, ya que el modelo predice únicamente el *cierre administrativo* de la solicitud.

Reproducibilidad, contribuciones y uso de IA

Tras instalar R 4.6.2, Quarto y LaTeX y clonar el repositorio, ejecutar desde la raíz:

```
Rscript --vanilla instalar.R    ## Paquetes y herramientas necesarias
Rscript --vanilla analisis.R    ## Proceso que ejecuta el analisis
```

Lenguaje: R 4.6.2.

Entorno: `renv` (ver archivo `renv.lock`).

Entrada: `datos/caso08_nyc311.zip`, con verificación de MD5.

Información de sesión completa: `output/sessionInfo.txt`.

Tiempo de ejecución aproximada: 20 minutos

Contribuciones

Diego Barrios:	Desarrollo de informe y presentación.
Renato Bazaes:	Creación de repositorio, desarrollo de scripts de análisis.
Mauricio Campillay:	Desarrollo de scripts de análisis.
Bruno Zavala:	Desarrollo de informe y presentación.

Declaración de uso de IA

Herramienta y fecha: Claude Code (modelo Claude Opus 5.5), entre el 8 de noviembre y 10 de noviembre de 2026.

Propósito: programación, depuración, configuración del entorno reproducible y borrador de las secciones descriptivas del informe.

Partes afectadas: `analisis.R`, `instalar.R`, `R/00_entorno.R` a `R/06_reserva.R` y `README.md`.

Comprobaciones realizadas: ejecución completa desde un clon limpio desde la versión comprimida .zip.

Anexo

Caso	n	%
cerrada en > 168 h	99357	58.17
cerrada en $<= 168$ h	71158	41.66
sin cierre registrado	293	0.17

Cuadro 12: A.1. Auditoría de la respuesta por caso.

Métrica	Valor
n solicitudes	170808
n bbl distintos	33615
n_zip_distintos	182
fecha min	2021-01-01 06:01:26
fecha max	2023-12-31 23:49:24
prevalencia_Y	0.5834
pct Y sin cierre	0.17

Cuadro 13: A.2. Métricas descriptivas de la muestra analítica.

anio	BRONX	BROOKLYN	MANHATTAN	QUEENS	STATEN ISLAND	Unspecified	NA
2021	17869	15407	11302	6155	1179	1	1
2022	19690	17170	12298	7046	1346	0	0
2023	21261	17963	13235	7368	1515	2	0

Cuadro 14: A.3. Cobertura por año de creación y borough.

Variable	Interpretación	Tipo
unique_key	ID de la solicitud	texto
closed_date	fecha de cierre	fecha
status	estado final	categórica
resolution_description	texto de resolución	texto
resolution_action_updated_date	última actualización	fecha
due_date	fecha comprometida	fecha
created_date	fecha de ingreso	fecha
open_data_channel_type	canal de ingreso	categórica
agency	agencia	categórica
complaint_type	tipo de problema	categórica
descriptor	detalle del problema	categórica
descriptor_2	detalle adicional	categórica
location_type	tipo de localización	categórica
facility_type	tipo de instalación	categórica
borough	condado	categórica
community_board	distrito comunitario	categórica
council_district	distrito municipal	categórica
police_precinct	precinto policial	categórica
incident_zip	código postal	categórica
incident_address	dirección	texto
street_name	calle	texto
bbl	identificador de inmueble	texto
latitude	latitud	numérica
longitude	longitud	numérica

Cuadro 15: A.4a. Interpretación y tipo de cada variable.

Variable	% NA
facility_type	1e+02
council_district	1e-02
incident_zip	1e-02
descriptor	0e+00
location_type	0e+00
borough	0e+00
community_board	0e+00
police_precinct	0e+00
open_data_channel_type	0e+00

Cuadro 16: A.4b. Porcentaje de valores faltantes por variable.

Variable	Niveles
incident_zip	183
police_precinct	78
community_board	67
council_district	52
descriptor	8
borough	7
open_data_channel_type	2
location_type	1
facility_type	1

Cuadro 17: A.4c. Número de niveles por variable categórica.

Modelo	Hiperparámetros	Config.	Particiones	Minutos
M1: logística lasso	penalty = 0.00207	20	3	0.9
M2: árbol podado	cost_complexity = 0.000546	20	3	7.2
M3: boosting	trees = 100; min_n = 21; tree_depth = 3; learn_rate = 0.0908	20	3	3.7

Cuadro 18: A.5. Hiperparámetros elegidos, configuraciones evaluadas y costo de la búsqueda.

Grupo	Nivel	n	Prev.	Pred. media	Log-loss	Dif. ref.
mes	2023-01	5358	0.572	0.595	0.615	-0.068
mes	2023-02	5286	0.541	0.600	0.653	-0.042
mes	2023-03	5173	0.571	0.550	0.631	-0.052
mes	2023-04	4444	0.579	0.564	0.645	-0.036
mes	2023-05	4410	0.613	0.558	0.614	-0.055
mes	2023-06	4501	0.543	0.598	0.660	-0.034
mes	2023-07	5135	0.546	0.592	0.648	-0.046
mes	2023-08	5247	0.558	0.597	0.643	-0.046
mes	2023-09	5076	0.570	0.595	0.637	-0.047
mes	2023-10	5575	0.572	0.595	0.613	-0.071
mes	2023-11	5491	0.579	0.618	0.604	-0.077
mes	2023-12	5648	0.576	0.600	0.597	-0.085
canal	ONLINE	21681	0.527	0.555	0.636	-0.064
canal	PHONE	39663	0.590	0.608	0.625	-0.051
descriptor	BASIN/SINK	16729	0.661	0.670	0.639	-0.011
descriptor	BATHTUB/SHOWER	12732	0.656	0.680	0.645	-0.008
descriptor	BOILER	80	0.688	0.680	0.620	-0.021
descriptor	RADIATOR	4002	0.579	0.607	0.636	-0.045
descriptor	SEWER	128	0.711	0.670	0.613	-0.019
descriptor	STEAM PIPE/RISER	1610	0.066	0.142	0.272	-0.599
descriptor	TOILET	9446	0.631	0.669	0.657	-0.005
descriptor	WATER SUPPLY	16617	0.415	0.431	0.625	-0.117

Cuadro 19: A.6a. Errores en la reserva por mes, canal y detalle.

Distrito	n	Prev.	Pred. media	Log-loss	Dif. ref.
01	474	0.532	0.557	0.606	-0.093
02	836	0.583	0.597	0.613	-0.067
03	868	0.560	0.590	0.610	-0.078
04	371	0.566	0.565	0.619	-0.066
05	578	0.576	0.561	0.620	-0.062
...	...	...	...	...	...
50	296	0.632	0.623	0.591	-0.070
51	131	0.664	0.659	0.644	-0.006

Cuadro 20: A.6b. Errores en la reserva por distrito municipal (reducida por extensión).

Grupo	n	Pred. media	Tasa observada
1 % con mayor probabilidad	614	0.756	0.717
1 % con menor probabilidad	614	0.110	0.049
$p >= 0,9$	0	NA	NA
$p <= 0,1$	72	0.093	0.056

Cuadro 21: A.6c. Predicciones extremas en la reserva y tasa observada.

Borough	n	Prev.	Elegido	Referencia	Dif. ref.
BRONX	19690	0.5984	0.6147	0.6742	-0.0595
BROOKLYN	17170	0.6020	0.6275	0.6725	-0.0450
MANHATTAN	12298	0.6212	0.5903	0.6657	-0.0754
QUEENS	7046	0.5430	0.6498	0.6938	-0.0440
STATEN ISLAND	1346	0.6315	0.6279	0.6617	-0.0338

Cuadro 22: A.6d. Estabilidad por borough en las ventanas de validación de desarrollo.

Detalle	n	Prev.	Pred. media	Log-loss	Dif. ref.
BOILER	80	0.688	0.680	0.620	-0.021
SEWER	128	0.711	0.670	0.613	-0.019

Cuadro 23: A.6e. Detalles poco frecuentes en la reserva (menos de 1 % de las solicitudes).