¿Seguirá abierta en 7 días?

Predicción del cierre de solicitudes de plomería de HPD (NYC 311)

Diego Barrios Renato Bazaes Mauricio Campillay Bruno Zavala

Tópicos Aplicados en Estadística (EYP3407) · Pontificia Universidad Católica de Chile
Profesor: Eloy Alvarado · Ayudante: Andrés Díaz

12 de noviembre de 2026

El problema: priorizar el seguimiento al ingreso

Pregunta. Al ingresar una solicitud de plomería a HPD, ¿cuál es la **probabilidad de que siga sin cierre administrativo a los 7 días**?

Para quién. Equipos de HPD que deciden qué solicitudes seguir de cerca.

Decisión que apoya. Marcar al ingreso las solicitudes con mayor riesgo de demora.

Respuesta

$$Y = \begin{cases} 1 & \text{sin cierre registrado en las primeras 168 h} \\ 0 & \text{cierre dentro de 168 h} \end{cases}$$

Población	HPD · PLUMBING · ingreso 2021–2023
Unidad	Una solicitud (`unique_key`)
Horizonte	7 días desde `created_date`
Momento	Al ingreso de la solicitud
Tipo	Clasificación binaria con probabilidad

Alcance

Predicción retrospectiva, no causalidad. El cierre *administrativo* no prueba que el problema se resolvió.

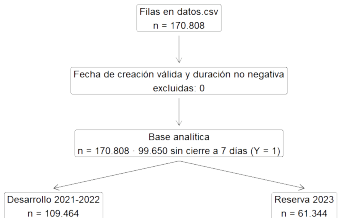
Datos y construcción de la muestra

Procedencia. NYC Open Data, *311 Service Requests from 2020 to Present* (`erm2-nwe9`); copia del curso del 12-10-2026, verificada por MD5.

Auditoría de fechas (se informa por separado):

Control	*n*	Decisión
Ingreso ausente o inválido	0	excluir
Cierre anterior al ingreso	0	excluir
Sin cierre registrado	293	conservar ($Y = 1$)
Cierre a medianoche exacta	7	conservar
Cierre >365 días después	417	conservar
<7 días de seguimiento	0	excluir

Ninguna exclusión: no se eliminan abiertas, para no alterar la población.



170 808 solicitudes · 33 615 inmuebles · **58,3 % con** $Y = 1$

Fuente: `output/tablas/calidad_fechas.csv`, `construccion_muestra.csv`, `descripcion.csv`

Información admisible y referencia

Regla: solo lo que se conoce **al ingreso**.

Se usa

Mes, día de semana y hora · canal · `descriptor`, `descriptor_2` · borough, distrito comunitario, distrito del concejo, precinto, código postal

Se excluye

`closed_date`, `status`, resolución, fechas de actualización, `due_date` (resultado o posterior) · `unique_key`, dirección (identificadores) · año (2023 no se ve al entrenar)

Historial sin fuga (3 variables):

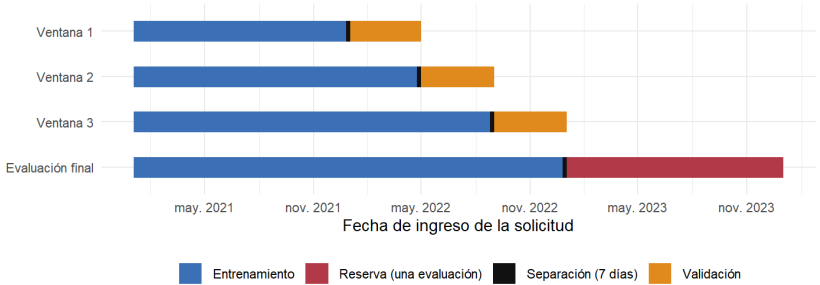
- Volumen del distrito en los 7 días previos
- Tasa sin cierre del distrito en 90 días, **solo con solicitudes cuyo plazo de 168 h ya terminó**
- Volumen del mismo inmueble en 90 días

Referencia

Tasa histórica de $Y = 1$ en el entrenamiento de cada partición, aplicada como probabilidad constante (0,585 · 0,591 · 0,589 · 0,592).

Fuente: `output/tablas/variables.csv`, `particiones.csv`

Particiones temporales con semana de separación



	Validación	*n* entrena	*n* valida
V1	ene–abr 2022	51 032	20 083
V2	may–ago 2022	71 001	17 152
V3	sep–dic 2022	88 057	20 315
Reserva	**2023 (una vez)**	107 640	61 344

- Entrena solo si **ingreso + 168 h** $\leq$ **origen**: su Y ya se conocía.
- Ventanas **expansivas**: imitan reentrenar con toda la historia.
- Métrica principal: **log-loss**. Regla: menor promedio; si uno más simple queda a $< 0{,}002$, se elige el simple.

Fuente: output/tablas/particiones.csv · output/figuras/diagrama_temporal.png

Tres procedimientos con el mismo presupuesto de búsqueda

Procedimiento	Qué puede captar	Búsqueda (20 configuraciones, 3 ventanas)	Elegido
M1 Logística lasso	Efectos aditivos; selecciona variables	penalización λ de 10^{-5} a 10^{-1} (escala log)	$\lambda = 0{,}00207$
M2 Árbol podado	Interacciones simples; interpretable	`cost_complexity` de 10^{-5} a 10^{-2}; mínimo 50 por nodo	$c_p = 0{,}000546$
M3 Boosting (xgboost)	Interacciones y no linealidades	100–600 árboles, profundidad 2–7, tasa 0,01–0,2, nodo mínimo 5–50	100 árboles, profundidad 3, tasa 0,091, nodo mínimo 21

Preprocesamiento dentro de cada entrenamiento

Nivel para categorías nuevas y faltantes · agrupar categorías $< 0{,}5\,\%$ · imputar mediana · indicadoras · quitar constantes · estandarizar (solo M1). **Nada se estima con la validación.**

Expectativas previas

M1: estable pero rígido. M2: interpretable pero inestable. M3: más flexible, más costoso y caja negra. Todos se comparan en las mismas filas.

Fuente: `output/tablas/hiperparametros.csv`, `grillas_log_loss.csv` · `R/03_modelos.R`

Desarrollo (2022): los tres superan a la referencia

Promedio de V1–V3, mismas 57 550 solicitudes de validación:

Modelo	Log-loss	Dif. ref.	Brier	AUC
M3 boosting	0,6163	−0,0580	0,2133	0,668
M1 lasso	**0,6182**	−0,0561	**0,2143**	**0,665**
M2 árbol	0,6193	−0,0550	0,2147	0,658
Referencia	0,6743	0	0,2406	0,500

Diferencia frente a la referencia por ventana (M1): −0,053 · −0,057 · −0,059. Mejora en las tres ventanas.

Selección (fijada antes de 2023)

M1 queda a **0,0018** de M3 ($< 0{,}002$) $\Rightarrow$ se elige **M1**: más simple, interpretable y barato (1,5 vs. 6,7 min de búsqueda).

Umbral

Índice de Youden en validación: **0,568**. Sobre ese valor, la solicitud se marca para seguimiento.

Fuente: output/tablas/comparacion_desarrollo.csv, desarrollo_por_ventana.csv, seleccion.csv

Reserva 2023: evaluación única con todo fijado

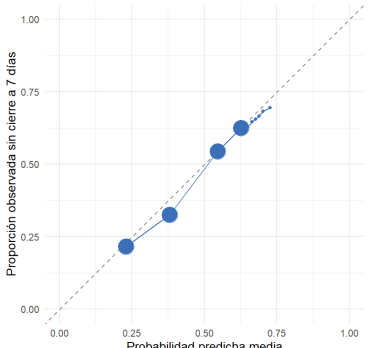
$n = 61\,344$ · prevalencia 56,8 %

Modelo	Log-loss	Dif. ref.	Brier	AUC
M2 árbol	0,6268	−0,0582	0,2188	0,653
M3 boosting	0,6274	−0,0577	0,2188	0,659
M1 lasso (elegido)	**0,6292**	−0,0559	**0,2198**	**0,656**
Referencia	0,6850	0	0,2459	0,500

M1 al umbral 0,568:

	Pred. sin cierre	Pred. con cierre
Real sin cierre	29 532	5 307
Real con cierre	15 687	10 818

Sensibilidad **84,8 %** · VPP **65,3 %** · Especificidad 40,8 %



Calibración por deciles: pendiente 1,06, intercepto −0,12. Leve **sobreestimación**: en 2023 hubo menos $Y = 1$ (56,8 %) que al entrenar (59,2 %).

Fuente: output/tablas/comparacion_reserva.csv, umbral_reserva.csv, calibracion_resumen.csv

Incertidumbre y diagnóstico de errores

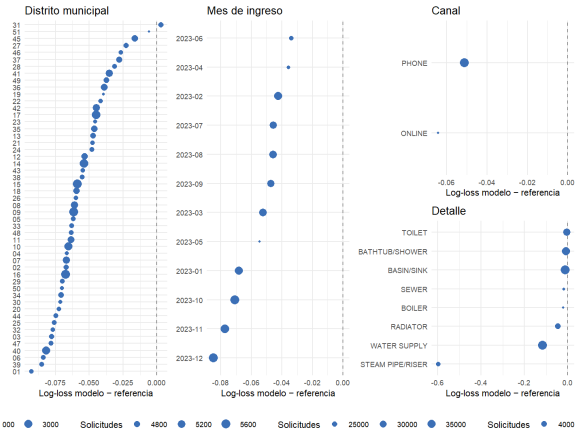
Bootstrap por conglomerados de la diferencia de log-loss M1 − referencia (−0,056), 2 000 réplicas, predicciones fijas:

Unidad	n	IC 95 %
Inmueble	18 082	[−0,060; −0,052]
Distrito	65	[−0,061; −0,051]
Semana	53	[−0,061; −0,050]
Mes	12	[−0,065; −0,046]

Ningún intervalo incluye 0. Condicional a los ajustes: no incluye la incertidumbre de selección.

Dónde no confiar

Distrito 31: único grupo donde el modelo no mejora a la referencia (+0,003; $n = 871$). Detalles raros (BOILER $n = 80$, SEWER $n = 128$): mejora mínima y poca evidencia.



Extremos: al 1 % de mayor riesgo le asigna 75,6 % (real 71,7 %); al 1 % de menor riesgo, 11,0 % (real 4,9 %). En las colas el modelo tiende a exagerar un poco.

Fuente: `output/tablas/incertidumbre_reserva.csv`, `errores_subgrupos_reserva.csv`, `detalles_raros_reserva.csv`

Sensibilidad (desarrollo) y recomendación

Mismos pliegues e hiperparámetros; cambia una decisión.
Diferencia de log-loss frente a la referencia:

Escenario	M1	M3	Regla elige
Base	−0,0561	−0,0580	M1
S1: sin historial	−0,0549	−0,0574	M3
S2: sin repetidas (22 %)	−0,0531	−0,0549	M1

- **S1, representación:** el historial aporta poco a M3 y algo más a M1; sin él, la regla elegiría M3.
- **S2, población:** sin repetidas por inmueble la ventaja se mantiene; no depende de duplicados.
- **Conclusión estable:** la mejora frente a la referencia ($\approx -0{,}055$) se sostiene en todos los escenarios.

Uso recomendado del modelo

1. **Misma población:** solo plomería de HPD en Nueva York, con los mismos canales y categorías.
2. **Priorización por riesgo:** AUC $\approx$ 0,66; ordena solicitudes, no predice con certeza un caso individual.
3. **Aceptar falsas alarmas:** detecta $\approx$85 % de las demoradas; cerca de un tercio de las marcadas cierra a tiempo.
4. **Recalibración periódica:** en 2023 sobreestima el riesgo; recalibrar umbral o referencia y monitorear.
5. **Calidad de entrada:** canal, detalle y ubicación bien registrados al ingreso y sin cambios posteriores.

Fuente: output/tablas/sensibilidad.csv · R/05_diagnostico.R

Límites y reproducibilidad

Limitaciones principales

- Conclusiones solo para plomería de HPD 2021–2023; no se extienden a otras agencias, categorías o periodos.
- Solo se observan solicitudes registradas: quienes no reclaman no aparecen.
- El cierre administrativo no equivale a resolución material.
- Copia revisada a octubre de 2026: evaluación retrospectiva, supone atributos estables tras el ingreso; no acredita rendimiento operativo real.
- Cierres ausentes tratados como no cierre al corte, aunque puede haber rezago.

No se recomienda usarlo

- En grupos con escasa evidencia (distrito 31, BOILER, SEWER).
- Para negar, postergar o restringir la atención de una solicitud.
- Para extraer conclusiones causales sobre las demoras.
- Como garantía de resolución: predice solo el cierre administrativo.

Reproducibilidad

Versión principal de R: 4.6.2, con Quarto y LaTeX.

Desde la raíz de una copia limpia del repositorio:

```
Rscript --vanilla instalar.R
Rscript --vanilla analisis.R
```

`renv` (129 paquetes fijados) · semilla 3407 · ∼20 min · MD5 del zip verificado · sesión en `output/sessionInfo.txt`.

Repositorio: `https://github.com/RenatoBazaesS/Proyecto-EYP3407-2026-2`

Diapositivas de apoyo

A1. Variables: disponibilidad y decisión

Variable	Disponibilidad	Decisión y razón
`created_date`	al ingreso	incluida como mes, día y hora; año excluido
`open_data_channel_type`	al ingreso	incluida
`descriptor`, `descriptor_2`	al ingreso (supuesto)	incluidas; categorías raras agrupadas
borough, community board, council district, police precinct, incident zip	al ingreso (supuesto)	incluidas; ubicación agregada
`bbl`	al ingreso	solo para historial, sensibilidad S2 y bootstrap
`closed_date`, `status`, resolución	posterior	excluidas: definen o revelan Y
`resolution_action_updated_date`, `due_date`	posterior / incierta	excluidas
`agency`, `complaint_type`, `location_type`	al ingreso	excluidas: constantes
`facility_type`	al ingreso	excluida: vacía
`unique_key`, dirección, calle	al ingreso	excluidas: identificadores, no se publican
latitud, longitud	al ingreso	excluidas: se usa ubicación agregada

Fuente: `output/tablas/variables.csv`

A2. Desempeño por ventana de validación

Log-loss	V1	V2	V3	Promedio
M1 lasso	0,6196	0,6233	0,6117	0,6182
M2 árbol	0,6253	0,6194	0,6133	0,6193
M3 boosting	0,6183	0,6209	0,6096	0,6163
Referencia	0,6722	0,6800	0,6707	0,6743
Prevalencia	60,4 %	58,1 %	60,7 %	
n validación	20 083	17 152	20 315	57 550

- Promedio simple de las tres ventanas; ponderado por *n* da el mismo orden y la misma selección (M1 a 0,0019 de M3).
- La dispersión entre ventanas muestra estabilidad; no es un intervalo de confianza (las ventanas comparten entrenamiento).

Fuente: `output/tablas/desarrollo_por_ventana.csv`

A3. Calibración por deciles y extremos (reserva)

Decil	$\bar{p}$ predicha	Tasa observada
1	0,230	0,215
2	0,381	0,325
3	0,546	0,544
4	0,627	0,625
5	0,649	0,628
6	0,664	0,646
7	0,677	0,655
8	0,689	0,666
9	0,703	0,682
10	0,727	0,694

Extremos (1 % de cada cola):

Grupo	$\bar{p}$	Observada
1 % mayor riesgo	0,756	0,717
1 % menor riesgo	0,110	0,049

Ninguna solicitud con $p \geq 0{,}9$; 72 con $p \leq 0{,}1$. Las probabilidades predichas quedan algo sobre lo observado en casi todos los deciles.

Fuente: output/tablas/calibracion_reserva.csv, extremos_resumen_reserva.csv

A4. Estabilidad por borough (desarrollo)

Borough	*n*	Prevalencia	Log-loss M1	Dif. ref.
Bronx	19 690	59,8 %	0,6147	−0,060
Brooklyn	17 170	60,2 %	0,6275	−0,045
Manhattan	12 298	62,1 %	0,5903	−0,075
Queens	7 046	54,3 %	0,6498	−0,044
Staten Island	1 346	63,2 %	0,6279	−0,034

El modelo elegido mejora a la referencia en los cinco boroughs; la mejora es menor en Staten Island, el de menor tamaño.

Fuente: output/tablas/estabilidad_borough_desarrollo.csv

A5. Preguntas probables

- **¿Por qué no validación cruzada aleatoria?** Predecimos solicitudes futuras; mezclar meses dejaría aprender del futuro y sobreestimaría el desempeño.
- **¿Por qué el hueco de 7 días?** La respuesta tarda 7 días en conocerse; sin el hueco, el entrenamiento usaría respuestas que aún no existían.
- **¿Por qué M1 si M3 era mejor?** La diferencia (0,0018) está bajo la tolerancia fijada de antemano; preferimos el modelo más simple.
- **¿Por qué no cambiar a M2 tras 2023?** La reserva mide; no elige. Cambiar después invalidaría la evaluación (§4.1).
- **¿Por qué log-loss?** El uso es ordenar por riesgo: importan probabilidades confiables, no solo acertar la clase.
- **¿Qué remuestrea el bootstrap?** Unidades completas (inmueble, distrito, semana, mes) con predicciones fijas; no incluye la incertidumbre de selección.
- **¿Las ventanas son comparables si crecen?** Dentro de cada ventana la comparación es pareada; entre ventanas comparamos la diferencia frente a la referencia.